

내 가게를 살리는 AI비밀상담사

데이터 기반 마케팅 솔루션

목차

01 프로젝트 개요

- 주제 및 목표
- 활용 데이터
 - 차별점
- 기대효과

02 배경 및 필요성

- 소상공인 마케팅 문제
- 데이터 기반 의사결정
 - AI 솔루션 필요성
 - 맞춤형 서비스

03 데이터 수집 및 활용

- 신한카드 가맹점 데이터
 - 외부 상권 정보
- 데이터 통합 방식
- 분석 프레임워크

04 모델 사용 환경

- 매출 변화 패턴
- 점진적 하락 감지
- 폐업 징조 포착
- 예측 모델 적용 범위

05 모델링 접근법

- 점진적 모델링
- 단일 vs 앙상블
- 예측 타겟 설정
- 하이퍼파라미터 튜닝


06 결과 및 결론

- 모델 성능 평가
 - 개선 방안
- LLM System Prompt
 - 우리 모델의 강점

프로젝트 개요

내 가게를 살리는 AI 비밀상담사	
차별점	- 예측 AI와 LLM의 혼합적 구조로 단순 설명이 아닌 점주 맞춤 마케팅 전략가 - 점주가 바로 실행할 수 있는 마케팅 전략
활용 데이터 및 기술	- 신한카드 가맹점 데이터(매출/고객/상권) - 외부 상권 정보(Open Data) - 트리기반 머신러닝 모델 , LLM(Gemini 2.5 Flash) - 웹 기반 챗봇 어플리케이션 프레임워크(Streamlit)
기대효과	- 점주가 쉽게 이해하고 바로 실행할 수 있는 솔루션 - 데이터 기반 의사결정 지원으로 매출 증대

배경 및 필요성



소상공인의 마케팅 역량 부족 및 어려움

- 대부분의 소상공인은 마케팅 전문 지식과 자원이 부족
- 데이터 분석 역량 부재로 고객 니즈 파악 어려움
- 인건비 상승, 원자재 가격 인상, 소상공인들의 경쟁 등 다양한 어려움

AI 기술을 활용한 해결 방안

- 가맹점 데이터 기반 맞춤형 마케팅 전략 제공
- AI 기술로 복잡한 데이터를 쉽게 이해하고, 문제 해결에 쉽게 활용 가능

데이터 수집 및 활용

신한카드 가맹점 데이터

- 가맹점 매출 데이터
- 고객 방문 패턴
- 결제 데이터

외부 상권 정보

- 개방 데이터 활용
- 네비 목적지 정보 관광객 수
- 상권 분석 시스템 데이터


데이터 통합 방식

- PK 기준 데이터 결합
- 결측치 처리
- 데이터 스케일링

분석 프레임워크


- 성동구 (상권, 기상, 인구) 데이터에 기반한 트리형 예측 모델 구축
- AI 예측모델 결과를 LLM이 해석하여 점주 맞춤형 마케팅 전략
- 챗봇 서비스 구현

모델 사용 환경에 대한 가정



매출 변화 패턴 분석

- 사용자 가맹점은 급격한 매출 감소 없이 서서히 변화
 - 이전 몇 개월 데이터에서 폐업 징조 포착
 - 점진적 매출 하락 패턴 감지 가능
 - 계절성 요인 반영 필요



예측 모델 적용 범위

- 매출 예측 및 고객 변화 탐지에 초점
- 전월 데이터를 보고 당월 매출을 예측
 - 상권 내 경쟁 업체 영향 분석
- 당장 실현해야 하는 마케팅 전략 제안

데이터 전처리 (1)

데이터 로드 및 무결성 확인	
키 기준 병합	- data2와 data3을 [ENCODED_MCT, TA_YM] 기준 Inner Join - 이후 data1을 [ENCODED_MCT] 기준 Left Outer Join
구간형 문자열 - 수치변환	- 값이 {하한}, {상한} 형태일 때 {하한}값 추출 이유: 숫자적 관계가 있는 열은 트리가 분할 기준으로 활용이 가능

데이터 전처리 (2)

```
_preprocess_data(df)
```

비식별/중복 우려 컬럼 정리

- MCT_BRD_NUM, MCT_SIGUNGU_NM, MCT_NM, MCT_BSE_AR 제거

날짜 컬럼 변환

- ARE_D, MCT_ME_D를 숫자에서 날짜 파싱 가능한 형태로 변환(오류는 결측 처리)

데이터 전처리 (3)

기존 데이터를 활용한 Feature Engineering 수행

폐업 여부 판단을
위한 Survive 컬럼 생성

- 데이터의 기준연월(TA_YM)이 폐점일(MCT_ME_D)의 월과 일치하는지 확인
- Survive 컬럼에 True/False 값으로 표현

매장 생존일(day_diff) 컬럼 생성

- 개점일(ARE_D)과 폐점일(MCT_ME_D) 간의 날짜 차이 계산
- 매장의 생존 기간을 일 단위로 수치화
- 생존 기간과 폐업 위험 간의 상관관계 분석 가능

상권정보
(HPSN_MCT_BZN_CD_NM)
컬럼 활용

- 이전 모델에서 결측치로 인해 제외되었던 데이터 활용
- Nan 값을 결측치가 아닌 '비상권'으로 대체 처리
- 상권 유무에 따른 매출 패턴 차이 분석 가능

모델링 접근 방식

예측 타겟 설정

- 가맹점별 마지막 월 데이터를 test로 분리
- 데이터 누수 방지를 위한 Train, Validation 데이터셋 분리
- 타겟 컬럼 'RC_M1_SAA' 예측 타겟 적용

N월 데이터로 N+1월 예측 방식 적용

- 실사용 시 N월을 보고 N을 예측하면 월초의 예측값과 월 말의 예측값 상이
- 중·장기 예측은 빠른 유행 변화에 반응하기 어려움
- 주 사용자층은 가게 상황이 좋지 않은 사장이라고 가정하고 당장 실현 가능한 방안을 제안하기 위해 단기예측

모델 구현 (1): XGBoost 단일 모델

모델 선택 이유	튜닝 과정	최적의 하이퍼파라미터	성능 평가
방문자 수, 검색량, 기온 등 연속형 숫자 데이터 비선형 관계 학습 능력 데이터 크기 중간 규모	Grid Search 방식 활용 5-fold 교차 검증 적용 learning_rate, max_depth 등 조정	n_estimators: 100 learning_rate: 0.1 max_depth: 5 subsample: 0.8 colsample_bytree: 0.8	R ² 성능: 0.844 RMSE = 0.569 MSE = 0.324

XGBoost 모델은 높은 성능(R² 0.844)을 보이고 있으며, 특성 중요도 분석을 통해 폐업 예측에 중요한 요인을 파악할 수 있음.
즉, 점주에게 실질적인 마케팅 조언을 제공할 수 있음.

모델 구현 (2): Catboost 단일 모델

모델 선택 이유	구현 과정	최적의 하이퍼파라미터	성능 평가
범주형 변수(기준년월, 거리구분명, 방문자연령 등) 포함 거리나 연령대 등 수치지만 실제론 범주형 의미를 가진 변수가 많음 기상 데이터나 관광객 통계 등 결측값 발생 가능성 존재	문자열 변수는 정수형 코드로 변환 Python 라이브러리 활용 Cross Vaildation 적용 Early Stopping 설정	iterations: 1000 learning_rate: 0.03 depth: 6 loss_function: RMSE	$R^2 = 0.836$ RMSE = 0.581 MSE = 0.337

Catboost 모델은 범주형 변수가 많은 가맹점 데이터에 적합한 알고리즘으로, 자동 인코딩 기능과 결측치 처리 능력이 뛰어남.
특히 Ordered Boosting 방식을 통해 과적합을 효과적으로 방지하며, 다양한 하이퍼파라미터 조정을 통해 예측 성능을 최적화할 수 있음.


모델 구현 (3): Ensemble - Stacking

Base model 구성

XGBoost: 그래디언트 부스팅 기반
LightGBM: 트리 기반 고속 학습
Catboost: 범주형 변수 자동 처리
각 모델의 예측값을 메타 모델의 입력으로 활용

Meta model 구성

XGBoost를 Meta model로 선정
Base model의 예측값을 입력으로 받음
- 현재 R^2 성능: 0.979




Stacking 선택 이유

Bagging: 데이터가 다차원적이라 적합하지 않음
Boosting: 단일 모델의 개별 성능은 좋지만 유형마다 특화
Stacking: Base 모델(XGB, LGBM, CatBoost)의 예측 결과를
Meta 모델이 학습하여 비선형 패턴을 학습

Stacking Ensemble

스태킹 앙상블은 Base model의 예측 결과를 입력으로 받아
최종 예측을 수행하는 Meta model을 사용하는 방식
각 모델의 장점을 결합하여 단일 모델보다 더 정확한 예측을 가능
다양한 패턴을 가진 가맹점 데이터에서 효과적 작동

성능 비교




XGBoost


매출 변동의 약 85%를 설명하여 매출 구간을 비교적 상세하게 예측 가능
상위 구간에서 개선 한계 (카테고리형 변수 처리)

CatBoost

자동 인코딩 과정으로 인하여 데이터에서의 학습 속도가 느려
실사용 효율이 떨어짐



성능 비교



Ensemble - Stacking

예측 성능 향상으로 매출 구간별 마케팅 전략을 보다 정밀하고 올바른 방향으로 제안
훈련 데이터와 검증 데이터 모두에서 일관된 성능을 보임

LLM System Prompt

○

다음은 테스트 매장의 현재 상황과 AI 분석 결과입니다:

{store_analysis}

사용자 질문: {chat_input}

중요 지침:

위에 나열된 "목표 예측을 위한 가장 중요한 요인 (상위 5개)"은 예측 모델에 따라 **목표 값에 가장 큰 영향을 미치는 변수**들입니다. 이는 실제 성과를 유도하는 요인에 대한 데이터 기반 인사이트입니다.

마케팅 전략 추천을 제공할 때:

가장 높은 특성 중요도 점수를 가진 상위 3~5개의 요인에 집중하십시오.

이러한 핵심 요인들의 현재 값을 분석하십시오.

○

이 요인들을 개선하거나 활용하기 위한 구체적이고 실행 가능한 마케팅 전략을 제시하십시오.

데이터 분석가가 아닌 마케팅 전략가의 관점에서 생각하십시오.
데이터 인사이트를 비즈니스 행동으로 번역하십시오.

예를 들어:

높은 중요도를 가진 요인의 현재 값이 낮을 경우 → 이를 개선하기 위한 구체적인 마케팅 캠페인이나 운영상의 변화를 제안하십시오.

높은 중요도를 가진 요인의 현재 값이 이미 높을 경우
→ 이 강점을 유지하고 강화하기 위한 전략을 추천하십시오.


중요도 점수와 실행 가능성을 모두 고려하여 개선의 우선순위를 정하십시오.

당신의 답변은 모델이나 데이터에 대한 기술적 설명이 아니라, **식당 운영자가 실제로 실행할 수 있는 실질적인 마케팅 조언**이어야 합니다.
고객 유치, 유지, 프로모션 전략, 운영 개선, 경쟁력 확보에 초점을 맞추십시오.

Chatbot Response

이러한 전략들을 체계적으로 실행하고 주기적으로 효과를 측정하여, 귀사의 매출을 동종 업계 평균 이상으로 끌어올리고 안정적인 고객 기반을 구축하시기를 바랍니다. 특히, 데이터를 통해 나타난 '거주 고객 0%'와 '낮은 매출액/고객 수/객단가' 문제는 최우선적으로 해결해야 할 지점임을 강조합니다.

마케팅 전략을 보고서 형식으로 가시성을 높임
Feature Importance 기반 실행 우선순위 제공



Gauge plot을 활용하여 점주가 자신의 매장을 상황을 직관적으로 이해 + 피드백에 대한 궁금증 유발