

P.4

Q. ARE_D 는 뭔지?

A. 개점일

Q. 상권정보 부분은 기존에 어떻게 처리했었는지?

A. 다른 컬럼의 경우 결측값이 아니면서 값이 없는 경우 별도의 값으로 처리를 해서 제공해줬지만 이 컬럼은 Nan 으로 존재하길래 단순 결측값으로 판단했고, Nan 비율이 상당히 커서 column drop 을 했었음. 하지만 모든 매장이 특정 상권에 포함되는 것은 아니라는 사실을 파악하고 Nan 값은 비상권처리함.

P.5

Q. 데이터 병합 기준은?

A. 월별 데이터이므로 기준연월(TA_YM)을 키값으로 병합함.

Q. 데이터가 이게 다인가?

A. 정부 db 화재로 접속 불가

P.6

Q. 스택킹 앙상블이 뭔지?

A. Base model로써 각각의 모델을 학습시키고, 그 모델들의 prediction 값들을 Meta model의 feature로 사용하여 학습하는 앙상블 방식. 과적합의 위험이 있기에 regularization이 불가피함.

P.7

Q. 기존에 N월을 보고 N월을 예측했던 이유는?

A. 사용자가 쿼리를 던질 때 카드사측 DB에 당월 라이브 데이터를 불러와서 예측이 진행되는 파이프라인으로 가정하고 개발을 했었음. 하지만 그렇게 되면 당월 데이터는 값들이 월초와 월말과 같이 시기마다 다르기 때문에 예측의 불안정성이 판단되어 가정을 바꿔 전월 데이터를 보고 당월을 예측하여 피드백하도록 수정

P.8

Q. 7페이지의 기존 예측 방식과 이 페이지의 기존 metric 과 내용이 좀 다른데 뭐가 맞는지?

A. 이 페이지 내용이 더 과거의 변경 과정이고, 그 이후에 변경된 metric 으로 진행하다가 예측방식을 변경했음.

P.9

Q. store analysis 에 뭐가 들어감?

A. 모델의 feature importance 값이 높은 순서대로 5개의 변수명과 모델의 예측 결과가 들어감.

Q. 마지막에 한국어로 번역하도록 하는 이유는?

A. LLM 모델이 많이 발전되었다고 해도 데이터가 영어가 훨씬 많음. 따라서 영어로 쿼리를 주고, 작업도 영어로 한 후 마지막에 결과물을 한국어로 번역해서 출력하라고 하면 많은 경우에서 결과물의 퀄리티가 더 좋았음. 따라서 그렇게 진행함.

P.10

Q. 스택킹 앙상블 모델의 R2 값이 xgboost 단일 모델과 같으면 더 가벼운 모델을 쓰는게 맞지 않음?

A. 현 시점이 최대 성능이라면 그게 맞지만 스택킹 앙상블 모델의 흔한 문제인 overfitting 조차 나오지 않았기 때문에 하이퍼파라미터 튜닝을 통해 성능 개선의 여지는 충분하다고 생각함. 추가적으로 오늘 오전에 optuna 로 추가 시도를 해본 결과 0.9 달성 성공했음.

Q. 9000 row 손실은 어떻게 계산된건가?

A. 데이터는 약 4700개의 가맹점 코드별로 24개의 시점 데이터가 존재하는데, 먼저 가장 최근 데이터는 test 데이터로 분리하고, 나머지 데이터중 N월을 보고 N+1월을 예측하도록 수정하면 마지막에서 두번째 데이터도 타겟만 활용되고 데이터는 사용되지 않음. 따라서 약 9000개의 row가 학습 대상에서 제외되었음을 의미.

P.11

Q. Optuna가 뭔지?

A. 자동으로 최적의 하이퍼파라미터를 탐색해주는 라이브러리임.