

1. 데이터 분할 전략

방식: [시계열_Hold-out 8:1:1]

- Train: 2023.01 ~ 2024.09
- Validation: 2023.01 ~ 2024.09
- Test: 2024.09 ~ 2024.12

그룹 누출 방지:

- 데이터 중복 방지: 가맹점, 기준연월 단위(ENCODED_MCT, TA_YM)로 분할하여 같은 점포의 데이터가 train/validation/test에 동시에 들어가지 않도록 함.
- 시점 누출 금지: 예측 시점 이전 데이터만 활용, 미래 매출/재방문 정보를 누설하지 않음

라벨 정의/원도우:

- 매출 예측: 다음 월 매출액 (회귀)
- 재방문 예측: 다음 월 재방문율이 6개월 평균 대비 +2%p 이상이면 긍정 라벨(분류)

2. 재현성 규칙

고정 시드: 42

버전관리:

- 코드: Git
- 데이터: DVC (Data Version Control)
- 모델/환경: MLflow + requirements.txt

실행 커맨드:

- 훈련: (mac) `python3 main.py --mode train --data ./dataset target RC_M1_SAA`
- 챗봇: `python3 main.py --mode streamlit`

3. 지표/통계

1차 KPI:

- 매출 예측: MAE (목표 $\leq 15\%$)
- 재방문 예측: Recall@Top10% (목표 ≥ 0.40)
- 추천 성능: NDCG@k

보조/가드레일:

- 추론 지연: < 5 초
- 비용/1000건 ≤ 50 원 (실사용시 기준. 공모전 참가 기준 시 0원)
- Δ FPR (연령/성별 그룹 간) ≤ 0.05

통계적 검정:

- 회귀 모델 비교: Paired t-test on prediction errors (예측 오차에 대한 대응표본 t-검정)
- 분류 모델 비교: Wilcoxon signed-rank test (다중클래스 라벨 예측 차이 검정)
- 신뢰구간: Bootstrap 95% CI

4. 에러 분석 계획

- 세그먼트별 분석: 업종(카페/한식/치킨), 상권(주거/업무/상업), 점포 규모별 성능 비교
- 임계값 민감도 분석: 재방문 상승 라벨 정의 $\Delta = +2\%p \rightarrow +1\%p, +3\%p$ 로 변경하여 모델 강건성 확인
- Top-N 오분류 점검: 상위 10% 타겟 추천에서 잘못 분류된 점포를 분석하여 공통

패턴 도출 (예: 신규점포, 결측률 높은 점포 등)

5. 윤리/법/보안

- 개인정보 최소화: ENCODED_MCT(비식별 코드) 사용, 개인 고객 ID 미사용
- 민감 특성 금지: 연령/성별은 집계 비율로만 활용, 개인 단위 데이터 미사용
- 접근권한/로깅:
 1. 데이터 접근 계정 제한
 2. 모든 학습/추론 로그 기록
 3. API 키는 제출 시 삭제

6. 운영 가정

- 배포 주기: 월 1회 모델 재학습
- 롤백 전략: 신규 모델 성능이 하락하면 직전 버전으로 즉시 복구
- 모니터링:
 1. Drift 감지 (입력 분포 vs 학습 분포 KL divergence)
 2. 성능 모니터링 (MAE/Recall@k 3개월 이동 평균)
 3. 알림: 성능 저하 시 Slack/이메일 알림 발송